

Análise Comparativa de Arquiteturas de Detecção de Objetos em Imagens: YOLOv8n *versus* SSD-MobileNet

Gabriel Freitas*, Álvaro Siqueira*, Israel da Silva Fernandes*,
Luiz Augusto Gomes da Silva*, Mateus de Jesus Venâncio de Souza*

*Departamento de Engenharia de Teleinformática, Universidade Federal do Ceará (UFC)
Fortaleza, Ceará, Brasil

Resumo—A detecção de objetos é uma tarefa central da visão computacional, com aplicações que vão do monitoramento de ambientes ao controle de estoque. Este trabalho apresenta uma análise comparativa entre duas arquiteturas de redes neurais profundas voltadas à detecção de objetos com complexidade computacional semelhante: a YOLOv8n, versão reduzida da família YOLOv8, e a MobileNet+SSD, baseada em convoluções separáveis em profundidade (*depthwise separable convolutions*). Os modelos foram treinados e avaliados em duas bases de imagens de classe única — uma base de maçãs fornecida pela disciplina e uma base de garrafas selecionada pelo grupo —, sob condições controladas e reproduzíveis. O protocolo experimental contemplou treinamento com parâmetros padrão, ajuste de hiperparâmetros, técnicas de pré-processamento, aumento de dados implementado manualmente e pós-processamento das predições, com cada configuração executada cinco vezes para cálculo de média e desvio padrão. Os resultados, reportados em termos de mAP, *precision*, *recall* e *F1-score*, evidenciam o compromisso entre custo computacional e qualidade de detecção das duas abordagens. Na base de garrafas, a YOLOv8n partiu de mAP@0,5 de 0,57 no cenário *baseline* e atingiu 0,95 ao combinar pré-processamento e ajuste de hiperparâmetros, evidenciando o peso do tratamento de imagem e da parametrização sobre o resultado final.

Index Terms—detecção de objetos, redes neurais convolucionais, YOLOv8, MobileNet, aumento de dados, processamento digital de imagens.

I. INTRODUÇÃO

A detecção de objetos consiste em localizar e classificar simultaneamente instâncias de uma ou mais categorias em uma imagem, delimitando-as por meio de caixas envolventes (*bounding boxes*) [1]. Diferentemente da classificação, que atribui um único rótulo à imagem inteira, e da segmentação semântica, que rotula cada pixel, a detecção fornece tanto a categoria quanto a posição de cada objeto, tornando-se fundamental em aplicações como vigilância, direção autônoma, controle de qualidade industrial e leitura automática de placas veiculares [2].

O avanço das redes neurais convolucionais (*Convolutional Neural Networks*, CNNs) [3] transformou a área, substituindo descritores manuais por representações aprendidas diretamente dos dados. Nesse contexto, destacam-se os detectores de estágio único (*one-stage*), que predizem caixas e classes em uma única passagem pela rede, favorecendo a operação em

tempo real. A família YOLO (*You Only Look Once*) [1] e os detectores do tipo SSD (*Single Shot Detector*) [4] são representantes proeminentes dessa categoria.

As duas arquiteturas comparadas neste trabalho inserem-se nesse paradigma. A YOLOv8n [5] é a variante *nano* da oitava geração da família YOLO: um detector sem âncoras (*anchor-free*) que, em uma única passagem, prediz caixas e classes a partir de mapas de características em múltiplas escalas, com arquitetura reduzida em profundidade e largura para operar sob restrição de recursos. Já o MobileNet+SSD combina o *backbone* MobileNet [6], baseado em convoluções separáveis em profundidade (*depthwise separable convolutions*), com o cabeçalho de detecção SSD [4], que realiza predições com âncoras em diferentes escalas. Embora ambas sejam detectores *one-stage* de complexidade comparável, partem de filosofias de projeto distintas — ausência *versus* uso de âncoras e *backbones* concebidos com objetivos diferentes —, o que torna a comparação tecnicamente relevante.

Este trabalho tem por objetivo desenvolver, treinar e avaliar dois modelos de detecção de objetos de complexidade semelhante, comparando-os não apenas pelas métricas de desempenho finais, mas também por fatores como custo computacional, tempo de treinamento, velocidade de inferência e capacidade de generalização. Como referência obrigatória da disciplina, adota-se a YOLOv8n; como segunda arquitetura, foi selecionada a MobileNet+SSD, cuja justificativa técnica é apresentada na Seção III. Os experimentos foram conduzidos sobre duas bases de classe única (maçãs e garrafas) e contemplam um *pipeline* progressivo de pré-processamento, aumento de dados e pós-processamento, descrito na Seção IV.

O restante do artigo está organizado da seguinte forma. A Seção II descreve as bases de dados utilizadas. A Seção III detalha as arquiteturas comparadas e a justificativa de escolha. A Seção IV apresenta a metodologia experimental, incluindo as técnicas de processamento. A Seção V reporta e discute os resultados. Por fim, a Seção VI traz as conclusões e os trabalhos futuros.

II. BASES DE DADOS

Foram utilizadas duas bases de imagens para detecção de objetos, ambas contendo uma única classe de objeto, conforme

exigido pelo enunciado do trabalho.

A. Base 1 — Maças (fornecida pela disciplina)

A primeira base, fornecida pelo professor, é composta por imagens contendo maçãs anotadas com caixas envolventes no formato COCO. Após a limpeza (remoção de uma imagem inválida), restaram 137 imagens, divididas em 97 para treino, 21 para validação e 19 para teste (aproximadamente 70/15/15). Com o aumento de dados manual, o conjunto de treino foi expandido para 553 imagens, totalizando 593.

B. Base 2 — Garrafas (selecionada pelo grupo)

A segunda base foi selecionada pelo grupo a partir do repositório público Roboflow Universe, atendendo aos critérios estabelecidos: acesso livre para fins acadêmicos, anotação por caixas envolventes, classe única (*garrafa*) e pertinência ao cotidiano de uma sala de aula. A escolha de garrafas justificase pela ampla variação de formas, materiais e condições de iluminação, o que torna a tarefa de detecção suficientemente desafiadora para evidenciar diferenças entre as arquiteturas. A base utilizada contém 236 imagens anotadas no formato COCO, obtidas do repositório público Roboflow Universe.

Tabela I
RESUMO DAS BASES DE DADOS UTILIZADAS.

Característica	Maças	Garrafas
Classe	maçã	garrafa
Total de imagens	137	236
Treino / Val / Teste	97 / 21 / 19	—
Divisão	70/15/15	80/20
Anotação	COCO (bbox)	COCO (bbox)
Fonte	Disciplina	Roboflow Universe

III. ARQUITETURAS DE REDE

A. YOLOv8n (referência)

A YOLOv8 [5] é um detector *one-stage* sem âncoras (*anchor-free*) que prediz caixas envolventes e classes diretamente a partir de mapas de características em múltiplas escalas. A variante *nano* (YOLOv8n) é a menor da família, com profundidade, largura e número de parâmetros reduzidos, o que a torna adequada para cenários com restrição de recursos computacionais e operação em tempo real. Foi adotada como referência obrigatória da disciplina.

B. MobileNet+SSD (escolhida pelo grupo)

Como segunda arquitetura, o grupo selecionou o SSDLite320_MobileNet_V3_Large, disponível na biblioteca *torchvision*. Trata-se de um detector *one-stage* do tipo SSD [4] com *backbone* MobileNetV3-Large e cabeçalho SSDLite, cuja principal característica é o uso de convoluções separáveis em profundidade (*depthwise separable convolutions*) [6], [7]. Essa fatoração da convolução padrão em uma etapa espacial (*depthwise*) seguida de uma combinação por pontos (*pointwise*) reduz drasticamente o número de operações e de parâmetros, mantendo capacidade de representação competitiva e tornando a rede adequada a

dispositivos móveis. O modelo foi adaptado para uma única classe (mais o fundo), totalizando `num_classes = 2`.

C. Justificativa da Comparação

A escolha da MobileNet+SSD não buscou uma arquitetura significativamente maior que a YOLOv8n — o que enviesaria a análise —, mas sim uma rede de *complexidade comparável* e de filosofia arquitetural distinta. Enquanto a YOLOv8n adota um projeto *anchor-free* otimizado de ponta a ponta, a abordagem SSD-MobileNet baseia-se em âncoras e em um *backbone* projetado primariamente para eficiência em dispositivos móveis.

Estudos preliminares sugerem que a MobileNet, voltada ao baixo custo computacional, tende a apresentar desempenho de detecção inferior ao da YOLOv8n. O objetivo da comparação é precisamente quantificar esse compromisso: avaliar se a eventual economia de recursos computacionais compensa a perda de qualidade de detecção, e em que medida técnicas de pré-processamento e aumento de dados mitigam as limitações de cada arquitetura na tarefa proposta. A Tabela II resume as características estruturais das duas redes.

Tabela II
COMPARAÇÃO ESTRUTURAL DAS ARQUITETURAS.

Característica	YOLOv8n	MobileNet+SSD
Paradigma	one-stage / anchor-free	one-stage / anchor-based
Parâmetros (M)	≈3,2	≈3,4
GFLOPs	≈8,7	≈0,6
Tamanho de entrada	640	320

Valores de parâmetros e GFLOPs conforme documentação das respectivas arquiteturas (Ultralytics e torchvision).

IV. METODOLOGIA EXPERIMENTAL

A. Ambiente Computacional

Todos os treinamentos e avaliações foram conduzidos no mesmo ambiente, a fim de garantir reprodutibilidade. A Tabela III especifica o hardware e as versões de *software* utilizados.

Tabela III
ESPECIFICAÇÃO DO AMBIENTE COMPUTACIONAL.

Componente	Especificação
Plataforma	Google Colab
GPU	NVIDIA Tesla T4 (16 GB)
RAM	≈12 GB
Python	3.11
CUDA	12.x
PyTorch	2.x
Ultralytics (YOLOv8)	8.x

B. Protocolo de Treinamento

Cada combinação de rede, base e configuração experimental foi treinada **cinco vezes**, reportando-se a média e o desvio padrão das métricas. Como configuração padrão adotaram-se 60 épocas, *batch size* de 16 e resolução de entrada compatível

com cada rede. Para o MobileNet+SSD utilizou-se o otimizador SGD com taxa de aprendizado de 0,005, momento de 0,9 e decaimento de peso de 5×10^{-4} . No MobileNet+SSD, a cada execução a base foi dividida em 80% para treino e 20% para validação, com semente de aleatoriedade distinta por execução ($seed = 42 + i$), assegurando que o conjunto de validação nunca recebesse dados aumentados; na base de maçãs (YOLOv8n) adotou-se a divisão fixa 70/15/15 descrita na Seção II. Os cenários *modificados* (tuning) ajustam hiperparâmetros a partir dessa configuração base.

C. Pipeline Experimental

Seguindo o protocolo do enunciado, os experimentos foram organizados de forma incremental, permitindo isolar o efeito de cada intervenção:

- 1) treino/teste com hiperparâmetros e parâmetros padrão;
- 2) treino/teste com hiperparâmetros e parâmetros modificados;
- 3) idem (1), acrescido de pré-processamento das imagens;
- 4) idem (2), acrescido de pré-processamento das imagens;
- 5) idem (2), acrescido de aumento de dados;
- 6) combinação de pré-processamento, parâmetros modificados e aumento de dados;
- 7) demonstração do pós-processamento sobre as predições.

D. Pré-processamento

A etapa de pré-processamento visou padronizar as entradas e realçar as características relevantes antes do treinamento. O pipeline aplicado à base de maçãs (YOLOv8n) foi composto por equalização adaptativa de contraste (*Contrast Limited Adaptive Histogram Equalization*, CLAHE), para melhorar o contraste, e filtro bilateral, que reduz ruído preservando as bordas. Para o MobileNet+SSD, o pré-processamento restringiu-se ao redimensionamento e à conversão para tensor.

E. Aumento de Dados (implementação manual)

Conforme exigência do enunciado, todas as técnicas de aumento de dados foram implementadas manualmente pelo grupo, com operações da biblioteca OpenCV, sem o uso de bibliotecas específicas para aumento de dados. As transformações foram aplicadas de forma estocástica a cada imagem de treino; nas transformações geométricas, as coordenadas das caixas envolventes são recomputadas junto com a imagem, garantindo que as marcações permaneçam corretas. Por terem sido conduzidos por integrantes distintos, os dois modelos empregaram conjuntos de transformações próprios, como detalhado a seguir.

a) *YOLOv8n*: Foram aplicados espelhamento horizontal, ajuste aleatório de brilho, ajuste aleatório de contraste e correção gama (*gamma correction*), buscando aumentar a variabilidade quanto a iluminação, orientação e contraste.

b) *MobileNet+SSD*: Foram aplicados espelhamento horizontal e uma transformação afim (rotação de $\pm 15^\circ$, translação de até 0,1 e escala entre 0,8 e 1,2), além de ajustes fotométricos de brilho e contraste, desfoque gaussiano e realce de nitidez, com as probabilidades indicadas na Tabela IV.

Tabela IV
TRANSFORMAÇÕES DE AUMENTO DE DADOS DO MOBILENET+SSD E RESPECTIVAS PROBABILIDADES DE APLICAÇÃO.

Transformação	Parâmetros	Prob.
Espelhamento horizontal	—	0,5
Transformação afim	rot. $\pm 15^\circ$, transl. 0,1, escala 0,8–1,2	0,7
Brilho / contraste	fator até $\pm 0,3$	0,8
Desfoque (<i>blur</i>)	gaussiano leve	0,2
Nitidez (<i>sharpen</i>)	kernel de realce	0,3

F. Pós-processamento

Sobre as predições brutas da rede foram aplicadas operações de refinamento: filtragem por limiar de confiança de 0,60 e supressão não-máxima (*Non-Maximum Suppression*, NMS) com limiar de IoU de 0,45, eliminando detecções redundantes sobrepostas. Conforme o enunciado, demonstra-se ainda a segmentação dos objetos detectados, obtida a partir da região interna de cada caixa envolvente resultante.

G. Métricas de Avaliação

Os modelos foram avaliados pelas métricas usuais de detecção de objetos [8]. A correspondência entre uma predição e um objeto real é estabelecida pela métrica de sobreposição *Intersection over Union* (IoU), definida como a razão entre a área de interseção e a área de união entre a caixa predita (B_p) e a caixa de referência (B_{gt}):

$$IoU = \frac{\text{area}(B_p \cap B_{gt})}{\text{area}(B_p \cup B_{gt})}. \quad (1)$$

Uma predição é considerada verdadeiro positivo (VP) quando seu IoU com um objeto real supera um limiar pré-definido; caso contrário, é um falso positivo (FP). Objetos não detectados constituem falsos negativos (FN). A partir dessas contagens definem-se a *precision* (P), que mede a proporção de detecções corretas, e o *recall* (R), que mede a proporção de objetos efetivamente encontrados:

$$P = \frac{VP}{VP + FP}, \quad R = \frac{VP}{VP + FN}. \quad (2)$$

O *F1-score* resume ambas em sua média harmônica, penalizando desequilíbrios entre precisão e revocação:

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R}. \quad (3)$$

A *Average Precision* (AP) corresponde à área sob a curva *precision–recall* de uma classe, e a *mean Average Precision* (mAP) é a média da AP sobre todas as classes — no caso de classe única, AP e mAP coincidem. Reportam-se duas variantes: a mAP@0,5, calculada ao limiar fixo de IoU de 0,5, e a mAP@0,5:0,95, média da mAP sobre dez limiares de IoU de 0,5 a 0,95 em passos de 0,05, métrica mais rigorosa adotada no desafio COCO. Foram ainda registrados os tempos de treinamento, teste, pré-processamento e pós-processamento.

H. Modalidades de Operação

Cada modelo otimizado foi avaliado em três modalidades: (i) imagens estáticas; (ii) sequências de vídeo, medindo consistência temporal e taxa de quadros por segundo (FPS); e (iii) captura em tempo real via *webcam*.

V. RESULTADOS E DISCUSSÃO

A. Base de Maças

B. Resultados do MobileNet+SSD

Tabela VI

RESULTADOS DO MOBILENET+SSD (MELHOR *checkpoint*, COM AUMENTO DE DADOS). MÉTRICAS OBTIDAS SOB PROTOCOLO PRÓPRIO — VER RESSALVA NO TEXTO.

Base	P	R	mAP
Garrafas	0,937	0,766	0,768
Maças	1,000	0,966	0,799

C. Base de Garrafas

D. Tempos de Treinamento

A Tabela VIII resume os tempos médios de treinamento por cenário da YOLOv8n na base de garrafas. Observa-se o custo crescente das configurações com aumento de dados: os cenários 5 e 6 custam cerca de dez vezes o tempo do *baseline*, sem proporcionar ganho de mAP em relação ao cenário 4.

Tabela VIII

TEMPO MÉDIO DE TREINAMENTO DA YOLOv8n (GARRAFAS), POR CENÁRIO, SOBRE 5 EXECUÇÕES.

Cenário	Tempo (min)
1. Original, padrão	20
2. Original, + tuning	39
3. Pré-proc., padrão	28
4. Pré-proc., + tuning	107
5. Augmentation, + tuning	216
6. Pré-proc. + aug., + tuning	225

E. Avaliação nas Três Modalidades

Os modelos otimizados foram exercitados nas três modalidades exigidas — imagens estáticas, vídeo e captura por *webcam* — por meio de uma aplicação interativa desenvolvida para a demonstração (Seção VI). Qualitativamente, os modelos apresentaram detecções estáveis e contínuas ao longo dos quadros de vídeo e na captura por *webcam*, mantendo o comportamento observado na avaliação por imagens.

F. Discussão

Sobre a comparabilidade entre as redes. As métricas da YOLOv8n e do MobileNet+SSD foram obtidas por rotinas de avaliação distintas: a YOLOv8n reporta mAP@0,5 e mAP@0,5:0,95 pelo protocolo padrão da biblioteca Ultralytics, enquanto o MobileNet+SSD foi avaliado por rotina própria, com limiar de confiança de 0,60 e NMS de 0,45. Por essa razão, os valores das Tabelas VII–VI *não devem ser comparados diretamente* entre as duas arquiteturas; a leitura

recomendada é a da evolução *intra-rede* ao longo dos cenários. A uniformização dos protocolos de avaliação é um ponto a ser tratado na consolidação final do trabalho.

Impacto do tuning. Na base de garrafas com a YOLOv8n, o ajuste de hiperparâmetros foi o fator de maior impacto isolado: o cenário 2 elevou a mAP@0,5 de 0,568 para 0,788 em relação ao *baseline*, e a combinação de pré-processamento com tuning (cenário 4) atingiu o melhor resultado global, mAP@0,5 = 0,952 e mAP@0,5:0,95 = 0,719.

Impacto do pré-processamento (garrafas). Isoladamente (cenário 3, sem tuning), o pré-processamento *não* melhorou o desempenho na base de garrafas — a mAP@0,5 caiu para 0,517, abaixo do *baseline*. O ganho só se materializou quando combinado ao ajuste de hiperparâmetros (cenário 4), sugerindo interação entre as duas intervenções. Na base de maçãs, em contraste, o pré-processamento (CLAHE e filtro bilateral) elevou a precisão para 0,995 e a mAP@0,5:0,95 para 0,800, o melhor valor dessa base.

Impacto do aumento de dados. Na base de garrafas, os cenários com aumento de dados (5 e 6) não superaram o cenário 4 em mAP, apesar de custarem aproximadamente o dobro do tempo de treinamento — indicando custo sem ganho proporcional, possivelmente por já haver diversidade suficiente após o tuning. Na base de maçãs, por outro lado, o aumento de dados foi determinante: elevou a mAP@0,5 de 0,899 para 0,993. O efeito do aumento de dados, portanto, mostrou-se dependente das características de cada base.

Estabilidade. A ausência de variação entre as cinco execuções de cada cenário (desvio padrão nulo) indica um processo de treinamento altamente reprodutível para as configurações avaliadas.

VI. CONCLUSÃO

Este trabalho comparou duas arquiteturas de detecção de objetos de complexidade semelhante — YOLOv8n e MobileNet+SSD — em duas bases de imagens de classe única, sob um protocolo experimental controlado e reprodutível. Na base de garrafas, a YOLOv8n alcançou seu melhor desempenho com a combinação de pré-processamento e ajuste de hiperparâmetros (mAP@0,5 = 0,952), enquanto o aumento de dados não trouxe ganho proporcional ao custo computacional adicional. A análise evidenciou o compromisso entre custo computacional e qualidade de detecção, bem como o papel das técnicas de pré-processamento, aumento de dados e pós-processamento na melhoria dos resultados.

Como trabalhos futuros, destacam-se a ampliação das bases de dados, a investigação de outras técnicas de aumento de dados e a integração dos modelos a uma interface *web* para inferência interativa, permitindo o *upload* de imagens e a seleção do modelo de detecção.

REFERÊNCIAS

- [1] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.

Tabela V
RESULTADOS DA YOLOv8N NA BASE DE MAÇÃS, POR CENÁRIO (MÉDIA DE 5 EXECUÇÕES). *t*: TEMPO MÉDIO DE TREINO.

Configuração	P	R	F1	mAP@.5	mAP@.5:.95	<i>t</i> (s)
Original	0,801	0,832	0,816	0,899	0,713	68
+ Data augmentation	0,967	0,994	0,980	0,993	0,780	384
+ Aug. + pré-processamento	0,995	0,931	0,962	0,960	0,800	448

Em negrito, o melhor valor de cada métrica. O aumento de dados elevou fortemente o desempenho; o pré-processamento trouxe ganho adicional de mAP@0,5:0,95 e de precisão, com leve redução de recall.

Tabela VII
RESULTADOS DA YOLOv8N NA BASE DE GARRAFAS, POR CENÁRIO DO *pipeline* (MÉDIA DE 5 EXECUÇÕES; O DESVIO PADRÃO FOI NULO EM TODOS OS CENÁRIOS). *t*: TEMPO MÉDIO DE TREINO.

Cenário	P	R	F1	mAP@.5	mAP@.5:.95	<i>t</i> (min)
1. Original, padrão	0,755	0,460	0,572	0,568	0,326	20
2. Original, + tuning	0,856	0,659	0,745	0,788	0,589	39
3. Pré-proc., padrão	0,837	0,444	0,581	0,517	0,350	28
4. Pré-proc., + tuning	0,916	0,863	0,889	0,952	0,719	107
5. Augmentation, + tuning	0,910	0,825	0,866	0,941	0,684	216
6. Pré-proc. + aug., + tuning	0,931	0,853	0,890	0,920	0,677	225

As cinco execuções de cada cenário produziram métricas idênticas (desvio padrão nulo), indicando elevada estabilidade do treinamento. Em negrito, o melhor resultado.

- [2] S. Du, M. Ibrahim, M. Shehata, and W. Badawy, "Automatic license plate recognition (ALPR): A state-of-the-art review," *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 23, no. 2, pp. 311–325, 2013.
- [3] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [4] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, "SSD: Single shot multibox detector," in *European Conference on Computer Vision (ECCV)*, 2016, pp. 21–37.
- [5] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8," <https://github.com/ultralytics/ultralytics>, 2023, versão 8.0.0.
- [6] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, "MobileNets: Efficient convolutional neural networks for mobile vision applications," *arXiv preprint arXiv:1704.04861*, 2017.
- [7] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.
- [8] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, "The Pascal visual object classes (VOC) challenge," *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.